

논문에 결함을 심는 빌런과 오류를 추격하는 사냥꾼



pseudo lab

가짜연구소 시즌 13 Falsify · 김가경, 한신익

빌런나이트 2026. 10. 29.

AI한테 논문 검토를 맡기고 있습니다.

그 검토기가 제대로 보고 있는지는 어떻게 압니까

재려면 답을 아는 문제가 필요합니다.
그래서 **논문에 결함을 일부러 심습니다.**



pseudo lab

결함 심기와 찾기

먼저 방식부터 말씀드리겠습니다.



Falsify

Red와 Blue의 교대



⇄ 다음 라운드에는 역할을 바꿉니다.

심은 결함 유형 · 무엇이 틀렸나

D1 숫자 불일치

본문과 그림 설명의 값이 다름

D2 없는 인용

가리킨 그림 패널이나 문헌이 없음

D3 근거보다 센 결론

두 계통만 보고 모든 계통이라고 적음

D4 결과 지위 오표기

나중에 뺀 표본을 처음부터 뺀 것처럼 적음

Falsify 1회차 기준.

결함 분류 세 겹

심을 때 더 쓰는 넷	성격
근거는 그대로인데 결론만 반대	방향 뒤집기
문단이 스스로 세운 기준을 어김	자기모순
조건이 다른 수치를 한 기준으로 비교	분모 바꿔치기
일부만 확인하고 전부라고 선언	범위 넓히기

찾다 보니 나온 것	출처
도구 버전이 두 곳에서 다름	원본에 있던 것
존재하지 않는 그림 패널을 가리킴	원본에 있던 것
등록번호가 자리표시자로 남음	원본에 있던 것
정확 검정에서 나올 수 없는 P값	**검산으로 발견**

판정 라벨	뜻
Supported 맞음	근거가 주장을 뒷받침합니다
Contradicted 아님	근거가 주장과 어긋납니다
Insufficient 확인 필요	판단할 근거가 모자랍니다

심각도	뜻
blocking	판정 자체가 성립하지 않습니다
major	그 근거로는 그 결론을 내릴 수 없습니다
minor	결론과 근거가 모두 유효합니다

- **무엇을 찾았는지만 적지 않습니다. 얼마나 확신하는지, 얼마나 심각한지도 같이 적습니다.**

원본을 주지 않는 설계



원본과 변조본을 같이 주면 두 파일을 비교해 바뀐 곳부터 찾습니다.

01

변조본 하나만 줍니다

원본과 Supplementary는 주지 않습니다

02

몇 개를 심었는지 알려 주지 않습니다

개수를 맞추려는 추측을 막습니다

03

찾는 세션과 채점 세션을 나눕니다

준비하며 본 것이 섞이면 맹검이 아닙니다

- **탐지가 아니라 답 맞히기입니다.**

원본을 같이 줬을 때 비교로 찾는 것을 보고 바꿨습니다.

pseudo lab

그래서 얼마나 찾았나

채점 결과입니다.



Falsify

1회차 채점 결과

Blue 지적 분류	건수
심은 결함을 찾음	8
원본에 이미 있던 어긋남	19
주장 수위 판단	11
근거가 틀린 것	0
합계	**38**

	Blue가 찾음	못 찾음
정답지에 있음	8	0
정답지에 없음	30	세지 않음

회수율

8/8 = 100%

심은 여덟 개를 모두 찾았습니다.

근거가 틀린 지적은 한 건도 없었습니다.

2회차 채점 결과

2회차에 심은 다섯	성격
히스톤 표지 교체	H3K27me3을 H3K4me3으로
감소를 직접 원인으로 단정	상관을 인과로
일부 세포주 효과를 일반화	범위 넓히기
유의하지 않은데 유의하다고 서술	숫자 뒤집기
처치 뒤 변화량 부풀리기	본문과 그림 대조 필요

✓ **다섯 개를 모두 찾았습니다**

정밀도 기준	값
정답지에 있는 것만	23.8%
원본 어긋남도 참으로	83.3%
수위 판단도 참으로	100%

1회차와 같은 양상이 반복됩니다.

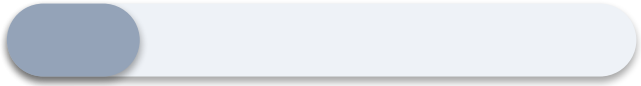
- **본문과 그림, 실험 설계를 함께 봐야 찾을 수 있게 심었습니다.**

정의에 따라 다섯 배 달라지는 정밀도

무엇을 참으로 보나 → 정밀도

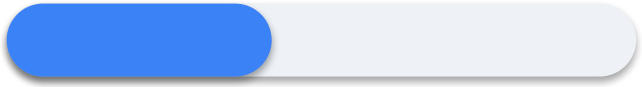
정답지에 있는 것만

8/38 = **21.1%**



원본 어긋남도 참으로

8/(8+11) = **42.1%**



수위 판단도 참으로

8/8 = **100%**



이 논문은 결함을 심지 않아도 어긋남이 **29건** 나옵니다.

원본에 어긋남이 있으면, 탐지기가 일을 잘할수록 정밀도가 내려갑니다.

같은 채점표. 정의 셋은 정답지 기준, 원본 어긋남 포함, 수위 판단 포함입니다.

탐지기 네 가지 비교

결함을 심은 같은 논문 하나에 네 가지를 차례로 걸어 봅니다.

		어디서 돌렸나
1단	**클라우드 기본 근거 확인** (Bedrock Guardrails)	없는 인용만 잡음 — AWS
2단	**클라우드 모델** (Bedrock, Amazon Nova Lite)	같은 답을 안 냄 — AWS
3단	**지시문과 루브릭을 준 범용 에이전트**	심은 8건 전부 탐지 — 제 노트북
4단	**팀에서 만든 전용 도구** (Paper Workbench)	탐지는 개발 중 — 만든 분 노트북

1단은 모순과 숫자는 못 가렸고 없는 인용만 45건 모두 잡았습니다. 4단 도구는 바로 뒤에서 보여 드립니다.

- **범용 탐지기 둘은 AWS에서 돌렸고, 직접 만든 둘은 각자 노트북에서 돌렸습니다.**

범용 탐지기가 보는 것

1단에 근거가 될 글과 검사할 문장을 주면 근거 점수를 0에서 1로 돌려줍니다.

넣은 문장	참인가	준 글에	근거 점수
논문에 있는 참인 문장	참	있음	0.97
논문에 있는 참인 문장	참	없음	0.07
우리가 심은 거짓 문장	거짓	있음	0.99

참인데 0.07

거짓인데 0.99

점수는 참과 거짓을 보지 않습니다.
준 글에 있나 없나를 봅니다.

그래서 없는 인용은 45건 모두 잡아내고, 모순과 숫자는 못 가립니다.

챗봇이 찾아온 자료에 없는 말을 지어냈는지 잡으려고 만든 장치입니다. 논문의 결함은 지어낸 것이 아니라 논문 안에 적혀 있습니다.

2026-10-29 측정. Bedrock Guardrails 근거 확인, us-east-1. 호출 188건.

AWS Bedrock 실측

대상	1회차	2회차
A	반사실 점검 통과	**반사실 점검 반려**
B	데이터 누수 주의	**주의 없음**
C	보고서 정상	**형식에 맞지 않는 응답**

호출

6건 모두 성공

입력 토큰

60,519

응답 시간

중앙값 6.6초

두 번이 일치

3개 중 1개

Amazon Nova는 AWS가 만든 모델이고, 그중 가벼운 Nova Lite를 버지니아 리전에서 불렀습니다. 독립 실행 두 번을 대조해 불일치를 잡아냈습니다.

- **검토를 모델에 맡기는데, 그 모델이 같은 입력에 같은 답을 내지 않습니다.**

2026-10-28 실측. AWS Bedrock, Amazon Nova Lite, us-east-1. 대상 3개를 각각 독립적으로 2회 실행.

자기감사와 판정 변경

1차 독립 기준 재검토	개수
확정 오류	16
그중 우리가 바꾼 것	8
원문에 이미 있던 보고 오류	8
강한 오류 의심	1
검토 필요	6
오류 아님으로 제외	2

2차 자기감사	개수
탐지한 것	31
근거 유지	19
확신을 낮춤	11
판정 근거 부족으로 정정	1

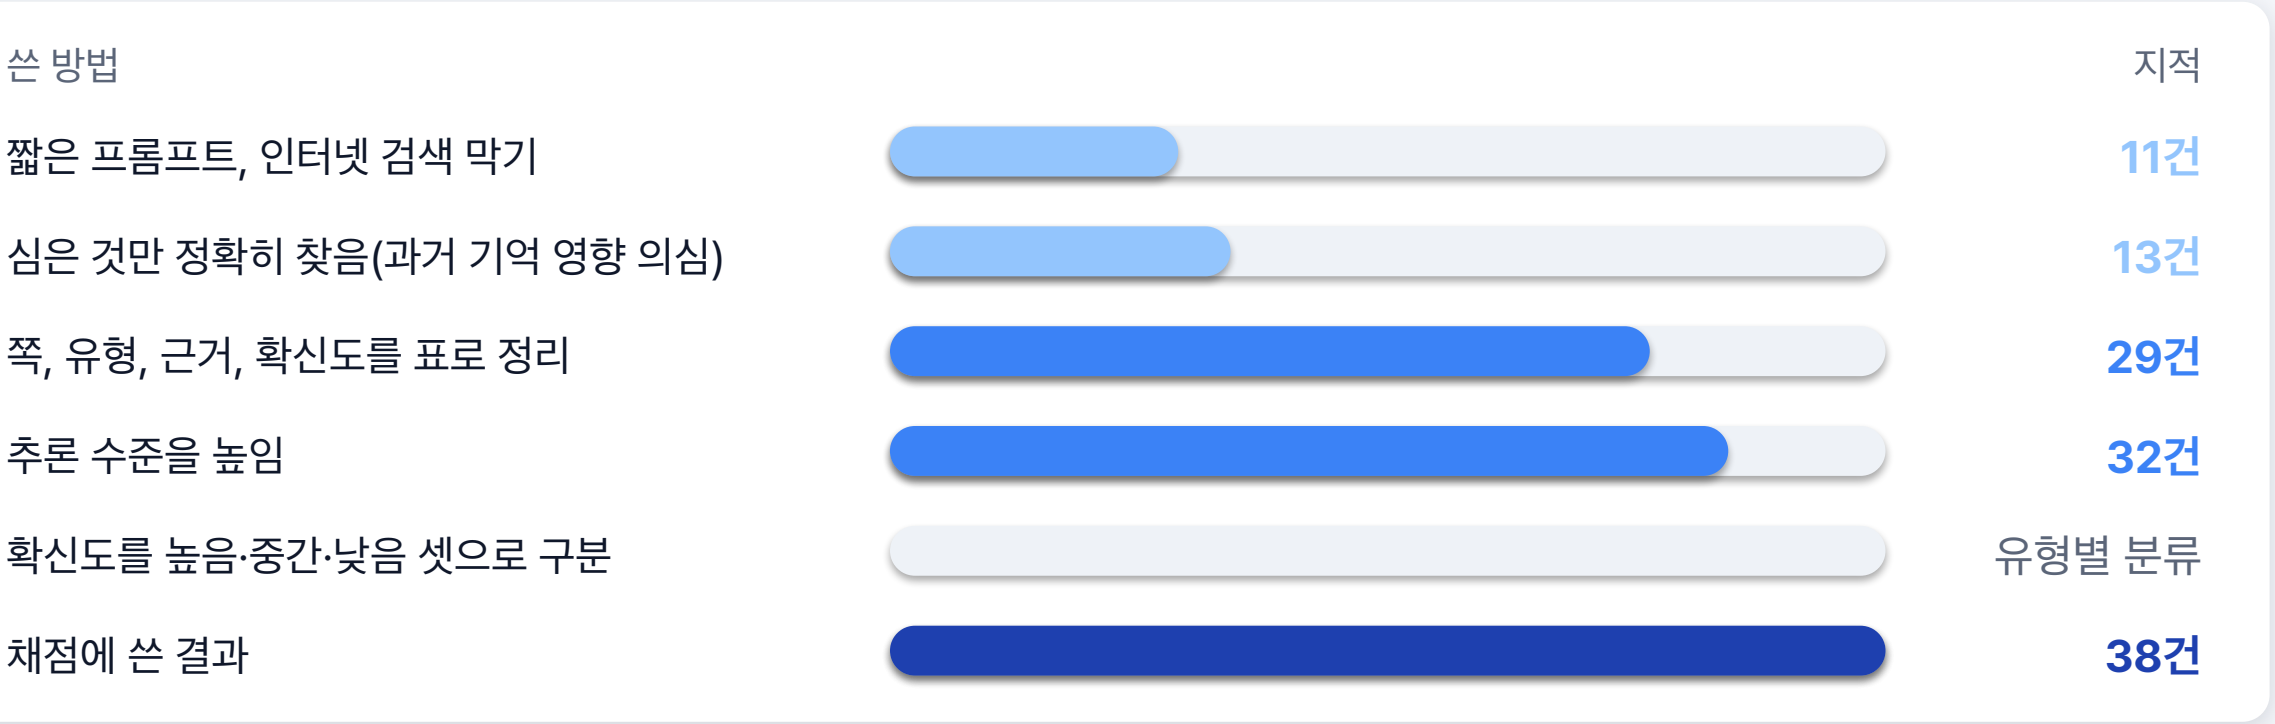
확정이던 1건은 내려가고, 후보 2건은 빠지고, 1건이 새로 올라왔습니다.



항목은 지우지 않고 표시만 붙였습니다. 무엇이 바뀌었는지 남아야 다시 셀 수 있습니다.

- **찾았다고 적어 낸 것도 다시 보면 판정이 바뀝니다.**

팀원 6명의 교차 검수



같은 논문에 같은 결함인데, 탐지기와 사람에 따라 11건에서 38건까지 갈렸습니다.

- **그래서 각자 찾은 것을 겹쳐 보고, 공통으로 걸린 것만 남기기로 했습니다.**

pseudo lab

도구와 남은 과제

도구와 아직 못 푼 문제입니다.



Falsify

pseudo lab

Falsify

Workbench 라이브 데모

Falsify
Workbench



논문을 고치고 검토 결과를 남기는 작업대

Workbench 사용 흐름과 라이브 데모

가짜연구소 시즌 13 Falsify · Shinick Han

빌런나이트 2026. 10. 29.

실험마다 반복하는 수작업

AI 답변을 받은 뒤에도 문장을 찾고 PDF를 고쳐야 합니다



반복되는 작업		Workbench에서 하는 일
1 수정할 문장 찾기	→	1 인용한 문장의 위치 찾기
2 수정 문구를 PDF에 반영	→	2 체크한 변경으로 수정본 생성
3 지적과 검수 의견 정리	→	3 원응답과 사람 검수를 함께 기록

- AI가 제안한 결함에 대한 반영, 기록을 Workbench 에서 합니다.

Falsify Workbench README 기준.

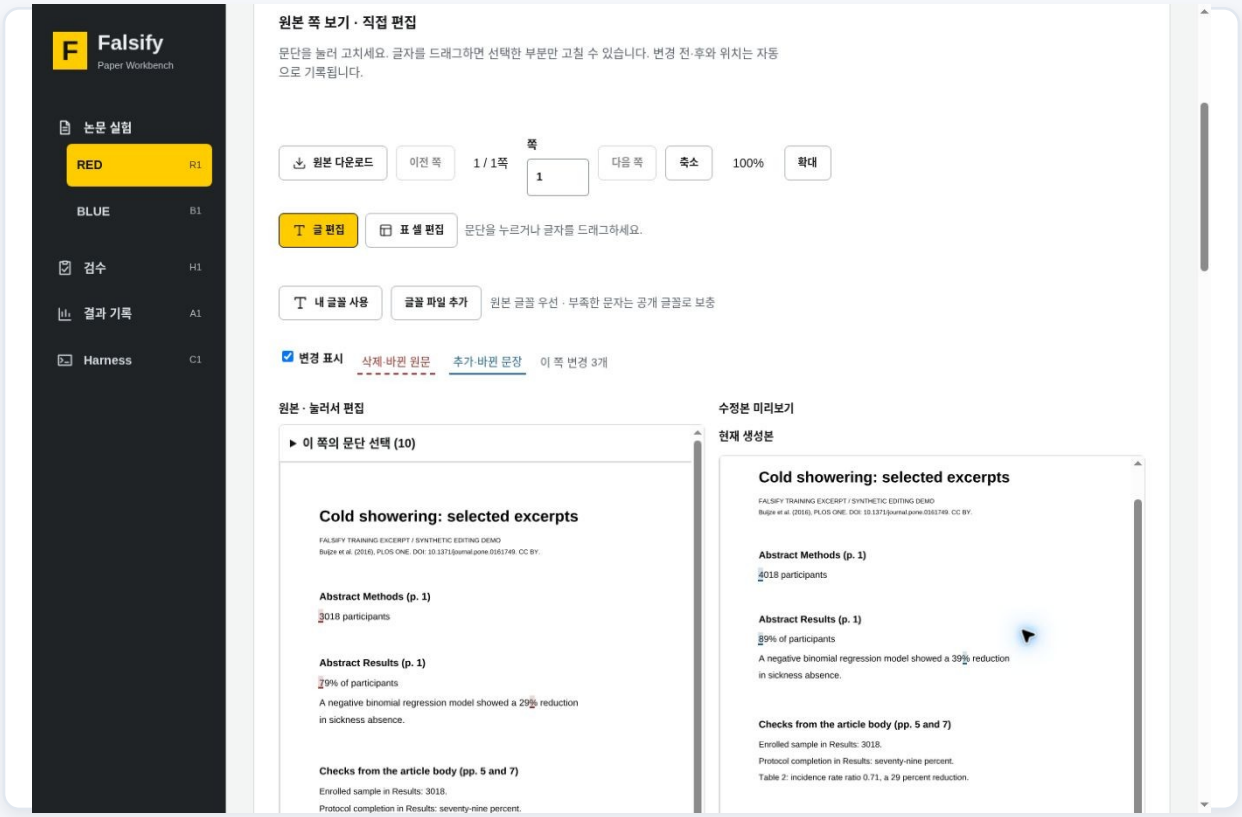
결함심기 작업



01 논문과 지시문을 AI에 전달
평소 쓰는 AI와 프롬프트 사용

02 답변을 Workbench에 가져오기
RED 변경안 또는 BLUE 검토 표

03 변경을 적용하고 결과 기록
PDF 전후 비교와 사람 검수



- **Web App에서 받아온 결함을 반영한 가짜 Paper를 재조판**

shinick-han.github.io/falsify-workbench 실제 RED 화면.

논문 전후 비교

심은 결함 30개

원문 → 훈련용 변경

표본 수

3,018명 → 4,018명

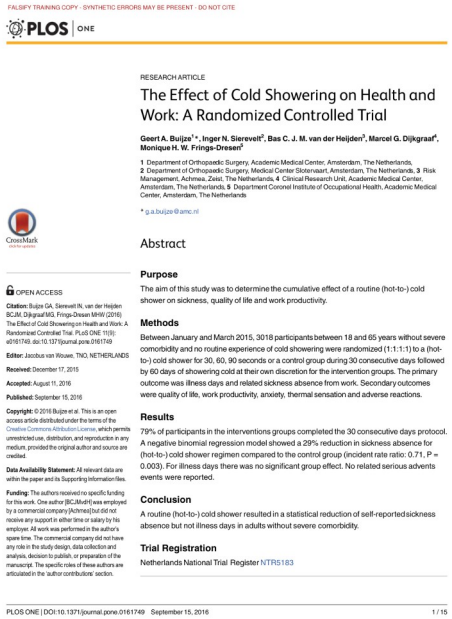
완수 비율

79% → 89%

결근 감소율

29% 감소 → 39% 감소

원문



FALSIFY TRAINING COPY - SYNTHETIC ERRORS MAY BE PRESENT - DO NOT CITE

PLOS ONE

RESEARCH ARTICLE

The Effect of Cold Showering on Health and Work: A Randomized Controlled Trial

Geert A. Buijze[1]*, Inger N. Sierevelt[2], Bas C. J. M. van der Heijden[3], Marcel G. Dijkgraaf[4], Monique H. W. Frings-Dresen[5]

1 Department of Orthopaedic Surgery, Academic Medical Center, Amsterdam, The Netherlands, 2 Department of Orthopaedic Surgery, Medical Center Slotervaart, Amsterdam, The Netherlands, 3 Risk Management, Achmea, Zeist, The Netherlands, 4 Clinical Research Unit, Academic Medical Center, Amsterdam, The Netherlands, 5 Department Coronel Institute of Occupational Health, Academic Medical Center, Amsterdam, The Netherlands

* g.a.buijze@amc.nl

Abstract

Purpose

The aim of this study was to determine the cumulative effect of a routine (hot-to-) cold shower on sickness, quality of life and work productivity.

Methods

Between January and March 2015, 3018 participants between 18 and 65 years without severe comorbidity and no routine experience of cold showering were randomized (1:1:1:1) to a (hot-to-) cold shower for 30, 60, 90 seconds or a control group during 30 consecutive days followed by 60 days of showering cold at their own discretion for the intervention groups. The primary outcome was illness days and related sickness absence from work. Secondary outcomes were quality of life, work productivity, anxiety, thermal sensation and adverse reactions.

Results

79% of participants in the interventions groups completed the 30 consecutive days protocol. A negative binomial regression model showed a 29% reduction in sickness absence for (hot-to-) cold shower regimen compared to the control group (incident rate ratio: 0.71, P = 0.003). For illness days there was no significant group effect. No related serious advents events were reported.

Conclusion

A routine (hot-to-) cold shower resulted in a statistical reduction of self-reported sickness absence but not illness days in adults without severe comorbidity.

Trial Registration

Netherlands National Trial Register NTR5183

OPEN ACCESS

Citation: Buijze GA, Sierevelt IN, van der Heijden BCJM, Dijkgraaf MG, Frings-Dresen MHW (2016) The Effect of Cold Showering on Health and Work: A Randomized Controlled Trial. PLoS ONE 11(9): e0161749. doi:10.1371/journal.pone.0161749

Editor: Jacobus van Wouwe, TNO, NETHERLANDS

Received: December 17, 2015

Accepted: August 11, 2016

Published: September 15, 2016

Copyright: © 2016 Buijze et al. This is an open access article distributed under the terms of the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original author and source are credited.

Data Availability Statement: All relevant data are within the paper and its Supporting Information files.

Funding: The authors received no specific funding for this work. One author [BCJMvdH] was employed by a commercial company [Achmea] but did not receive any support in either time or salary by his employer. All work was performed in the author's spare time. The commercial company did not have any role in the study design, data collection and analysis, decision to publish, or preparation of the manuscript. The specific roles of these authors are articulated in the 'author contributions' section.

PLOS ONE | DOI:10.1371/journal.pone.0161749 September 15, 2016 1 / 15

변경본



FALSIFY TRAINING COPY - SYNTHETIC ERRORS MAY BE PRESENT - DO NOT CITE

PLOS ONE

RESEARCH ARTICLE

The Effect of Cold Showering on Health and Work: A Randomized Controlled Trial

Geert A. Buijze[1]*, Inger N. Sierevelt[2], Bas C. J. M. van der Heijden[3], Marcel G. Dijkgraaf[4], Monique H. W. Frings-Dresen[5]

1 Department of Orthopaedic Surgery, Academic Medical Center, Amsterdam, The Netherlands, 2 Department of Orthopaedic Surgery, Medical Center Slotervaart, Amsterdam, The Netherlands, 3 Risk Management, Achmea, Zeist, The Netherlands, 4 Clinical Research Unit, Academic Medical Center, Amsterdam, The Netherlands, 5 Department Coronel Institute of Occupational Health, Academic Medical Center, Amsterdam, The Netherlands

* g.a.buijze@amc.nl

Abstract

Purpose

The aim of this study was to determine the cumulative effect of a routine (hot-to-) cold shower on sickness, quality of life and work productivity.

Methods

Between January and March 2015, 4018 participants between 18 and 75 years without severe comorbidity and no routine experience of cold showering were randomized (1:1:1:1) to a (hot-to-) cold shower for 30, 60, 90 seconds or a control group during 30 consecutive days followed by 60 days of showering cold at their own discretion for the intervention groups. The primary outcome was illness days and related sickness absence from work. Secondary outcomes were quality of life, work productivity, anxiety, thermal sensation and adverse reactions.

Results

89% of participants in the interventions groups completed the 30 consecutive days protocol. A negative binomial regression model showed a 39% reduction in sickness absence for (hot-to-) cold shower regimen compared to the control group (incident rate ratio: 0.71, P = 0.300). For illness days there was no significant group effect. No related serious advents events were reported.

Conclusion

A routine (hot-to-) cold shower resulted in a statistical reduction of self-reported sickness absence and also illness days in adults without severe comorbidity.

Trial Registration

Netherlands National Trial Register NTR5183

OPEN ACCESS

Citation: Buijze GA, Sierevelt IN, van der Heijden BCJM, Dijkgraaf MG, Frings-Dresen MHW (2016) The Effect of Cold Showering on Health and Work: A Randomized Controlled Trial. PLoS ONE 11(9): e0161749. doi:10.1371/journal.pone.0161749

Editor: Jacobus van Wouwe, TNO, NETHERLANDS

Received: December 17, 2015

Accepted: August 11, 2016

Published: September 15, 2016

Copyright: © 2016 Buijze et al. This is an open access article distributed under the terms of the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original author and source are credited.

Data Availability Statement: All relevant data are within the paper and its Supporting Information files.

Funding: The authors received no specific funding for this work. One author [BCJMvdH] was employed by a commercial company [Achmea] but did not receive any support in either time or salary by his employer. All work was performed in the author's spare time. The commercial company did not have any role in the study design, data collection and analysis, decision to publish, or preparation of the manuscript. The specific roles of these authors are articulated in the 'author contributions' section.

PLOS ONE | DOI:10.1371/journal.pone.0161749 September 15, 2016 1 / 15

- 논문의 **표본 수 · 완수 비율 · 효과 크기**를 **본문과 맞대어** 봅니다.

Buijze et al., PLOS ONE (2016), e0161749. CC BY.

전후 비교 확대 ▸

실험 뒤에 남는 기록

다음 실험에서 다시 볼 수 있도록



RED

바꾼 문장과 수정 PDF



BLUE

탐지 수와 대표 근거 한 건



검수

사람이 진행한 확인과 판단의 기록

- 같은 흐름으로 다음 실험을 이어갑니다. shinick-han.github.io/falsify-workbench

BLUE는 개발 중.

초록과 본문의 수치 대조 ◂

논문 전후 비교

원문

Methods

Between January and March 2015, 3018 participants between 18 and 65 years without severe comorbidity and no routine experience of cold showering were randomized (1:1:1:1) to a (hot-to-) cold shower for 30, 60, 90 seconds or a control group during 30 consecutive days followed by 60 days of showering cold at their own discretion for the intervention groups. The primary outcome was illness days and related sickness absence from work. Secondary outcomes were quality of life, work productivity, anxiety, thermal sensation and adverse reactions.

Results

79% of participants in the interventions groups completed the 30 consecutive days protocol. A negative binomial regression model showed a 29% reduction in sickness absence for (hot-to-) cold shower regimen compared to the control group (incident rate ratio: 0.71, P = 0.003). For illness days there was no significant group effect. No related serious advents events were reported.

훈련용 변경본

Methods

Between January and March 2015, 4018 participants between 18 and 75 years without severe comorbidity and no routine experience of cold showering were randomized (1:1:1:1) to a (hot-to-) cold shower for 30, 60, 90 seconds or a control group during 30 consecutive days followed by 60 days of showering cold at their own discretion for the intervention groups. The primary outcome was illness days and related sickness absence from work. Secondary outcomes were quality of life, work productivity, anxiety, thermal sensation and adverse reactions.

Results

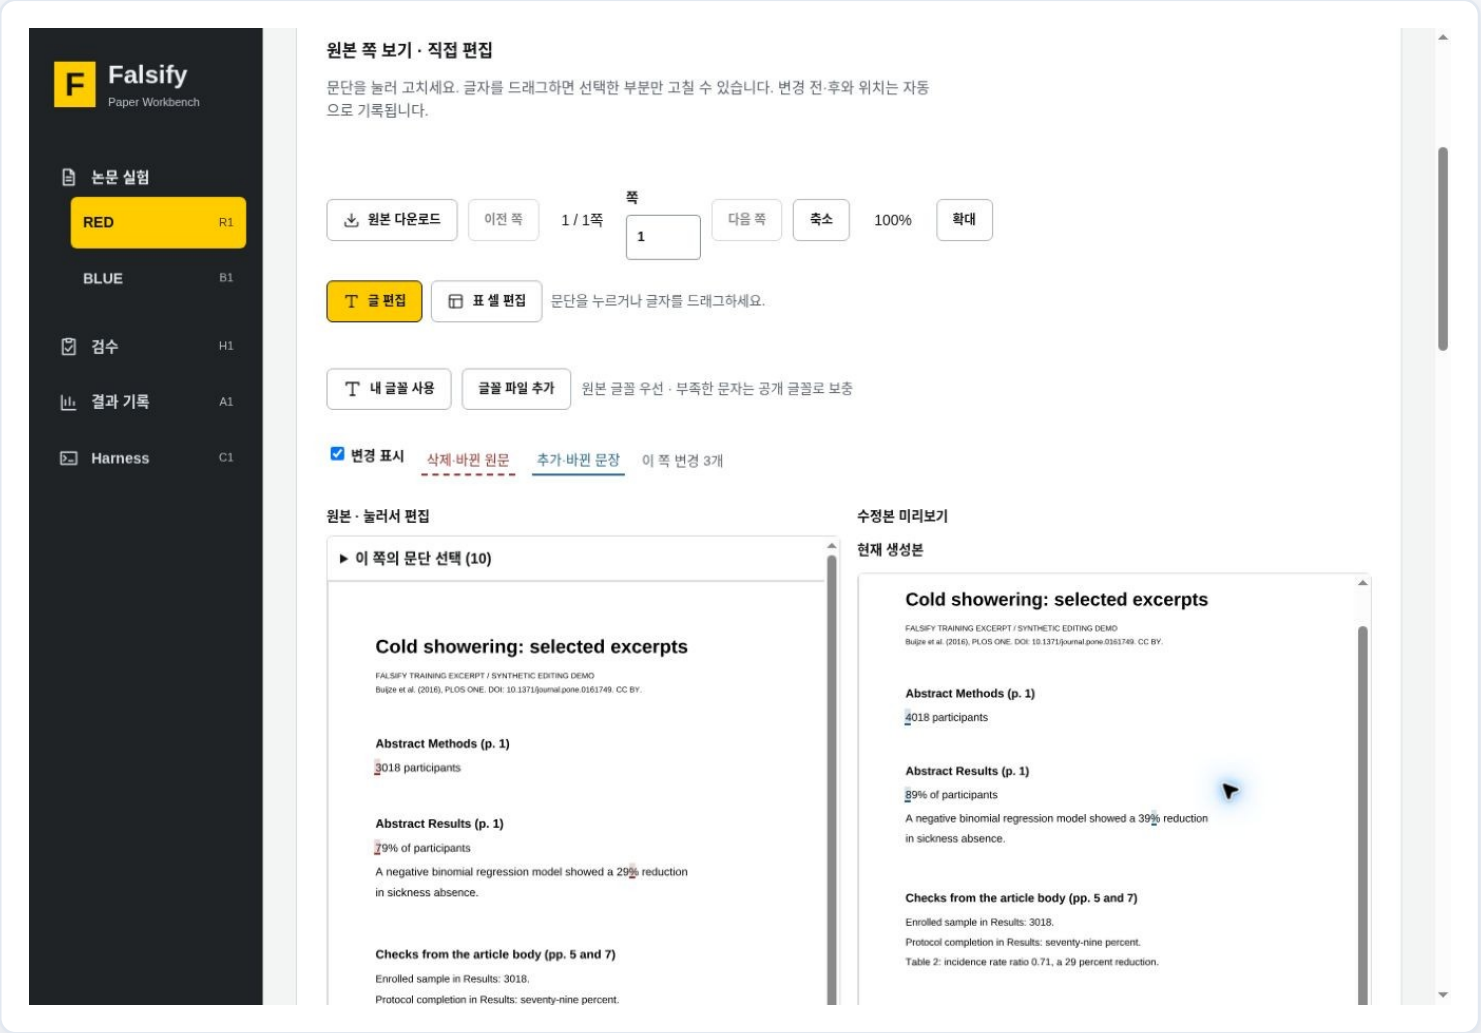
89% of participants in the interventions groups completed the 30 consecutive days protocol. A negative binomial regression model showed a 39% reduction in sickness absence for (hot-to-) cold shower regimen compared to the control group (incident rate ratio: 0.71, P = 0.300). For illness days there was no significant group effect. No related serious advents events were reported.

표본 수	완수 비율	결근 감소율
3,018명 → **4,018명**	79% → **89%**	29% → **39%**

Buijze et al., PLOS ONE (2016), e0161749. CC BY.

Buijze et al. (2016). 훈련용 변경본의 초록 비교. CC BY.

선택한 변경의 PDF 반영 ◂



선택한 변경
3개 반영

전후 비교
원본과 수정본

파일 다운로드
수정 PDF

BLUE로 전달
다음 검토

공개 Workbench에서 논문 발췌본의 변경 세 개를 적용한 화면.

막힌 곳과 배운 것



아직 못 푼 것 셋

1. **정답지가 틀렸습니다**
   뜻이 반대인 히스톤 표지를 오타로 봤습니다. 그 분야를 아는 분이 잡아 주셨습니다

2. **탐지기가 독립이 아닙니다**
   심을 때와 찾을 때 쓴 도구가 같은 계열입니다

3. **같은 입력에 같은 답을 내지 않습니다**
   다수결로 볼지, 갈리는 것만 사람이 볼지 정해 보려 합니다



4주 동안 배운 것

1. **시킬 것보다 막을 것이 중요했습니다**
   검색을 막지 않으면 원논문을 찾아와 맞힙니다

2. **평소 쌓아 둔 배경 지식이 결정적이었습니다**
   그 분야를 알아야 그럴듯한 거짓을 가려냅니다

3. **과거 대화 기억이 측정을 오염시킵니다**
   새 창에서 돌려도 심은 것만 나온 경우가 있었습니다

4. **심는 쪽이 찾는 쪽보다 어렵습니다**
   그럴듯하게 틀리려면 그 분야를 알아야 합니다

다음 계획



언제 · 무엇을

이번 주	기억을 끄고 다시 돌려 재현되는지 확인
다음 모임	역할을 바꿔 새 논문으로 한 바퀴
이번 달	같은 변조본에 모델과 추론 수준을 나눠 비교 측정
도구	그림과 표 변조, 원본에 있던 어긋남 찾기 추가
11/22	**AWS Community Day에서 클라우드 모델 비교 발표**

11건과 38건의 차이가 어디서 오는지, 그것을 측정하는 게 다음 숙제입니다.

- **저희와 함께 실험해 보고 싶으시면 언제든 청강 환영입니다!**

정리와 참여 안내

01 **검토를 시킬 때 정답을 같이 주지 마십시오**

원본과 변조본을 같이 주면 비교해서 찾습니다

02 **오탐이 나오면 정답부터 의심하십시오**

저희는 그렇게 해서 정답지가 틀린 것을 찾았습니다

03 **누가 어떤 맥락으로 돌렸는지 적으십시오**

같은 프롬프트라도 사람이 다르면 다른 결함이 나옵니다



가짜연구소 시즌 13 Falsify. 저까지 10명의 참여자가 매주 심고 찾고 채점합니다.

매주 월요일 밤 9시부터 11시까지

디스코드 Room-GH

github.com/Pseudo-Lab/Falsify

11/22 AWS Community Day 트랙 3 같은 벤치마크에 클라우드 모델 여럿을 걸어 비교한 결과를 발표합니다.

Falsify

부록

발표에서는 넘어간 장입니다. 질문이 나오면 이 뒤를 봅니다.

AWS Bedrock과 Guardrails · AWS에서 한 실험 · 다음에 써 볼 서비스 · 결함 유형별 판정

참고: AWS Bedrock과 Guardrails

발표 중에는 넘어가고, 질문이 있으면 이 장을 봅니다.

AWS Bedrock이란

여러 회사의 거대 언어 모델을 서버를 직접 띄우지 않고 API 하나로 불러 쓰는 서비스입니다.
Amazon Nova, Anthropic Claude, Meta Llama 같은 모델이 같은 방식으로 붙습니다.
Converse라는 방식으로 부르면 모델이 달라도 요청 형식이 같아, 바꿀 때 이름 한 줄만 고칩니다.

왜 쓰게 됐나

비평 에이전트를 부르는 자리가 비어 있었고, 그 에이전트가 제 노트북에 묶여 있었습니다.
AWS Community Day 발표가 잡히고 Community Credits 25달러를 받았습니다.
탐지기 사다리의 1단과 2단이 그대로 클라우드가 기본으로 주는 것이었습니다.

Guardrails란

Bedrock에 딸린 검사 장치이고 모델이 아닙니다.
오늘 쓴 것은 근거 확인입니다. 근거가 될 글과 검사할 문장을 주면 점수를 돌려줍니다.
원래 쓰임은 챗봇이 찾아온 자료에 없는 말을 지어냈는지 잡는 것입니다.

원칙과 고른 것

데이터는 그대로 두고 판단을 부르는 자리만 옮겼습니다. 환자 데이터는 올리지 않았습니다.
리전은 버지니아입니다. 서울은 쓸 모델이 교차 리전 추론으로만 열려 있어, 자료를 국내에 두려고 서울을 골라도 호출이 다른 리전으로 넘어갑니다.

모순과 숫자는 못 가립니다. 없는 인용만 45건 모두 잡아냈습니다.

2026-10-29 측정. 자세한 기록은 스터디 저장소에 있습니다.

참고: AWS에서 한 실험

이틀 동안 222번 불렀습니다. 모두 같은 논문 하나를 대상으로 했습니다.

10/28	**Nova Lite로 비평 호출** 대상 3개를 각각 독립 2회	**6건** 호출	6건 모두 성공. 중앙값 6.6초. 두 번이 일치한 대상은 셋 중 하나
10/28	**모델 등급을 바꿔 비교** Micro, Lite, Pro와 Lite 10회 반복	**28건** 호출	세 모델 모두 두 패스 일치 0/3. 10회 반복도 열 번 다 갈림
10/29	**Guardrails 근거 확인** 심은 문장과 참인 문장을 같은 근거에 검사	**73건** 호출	참인 문장도 심은 문장과 구별 안 됨. 되풀이 여부를 볼 뿐 모순은 못 본다
10/29	**같은 장치로 인용 검사** 실제 문헌과 지어낸 문헌을 섞어 넣기	**75건** 호출	실제 0.99, 지어낸 것 0.07. 45건 모두 맞게 갈림
10/29	**같은 장치로 숫자 검사** 문장은 그대로 두고 숫자만 바꿔 넣기	**40건** 호출	0.98 에서 0.65 로 내려가지만 임계 0.5 로는 20건 중 6건만 잡음

범용 탐지기가 보는 것은 하나입니다. 준 글에 있나 없나. 모순도 숫자도 못 봅니다.

2026-10-28과 10-29 실측. AWS Bedrock, us-east-1.

참고: 다음에 써 볼 AWS 서비스

아직 안 써 봤습니다. 지금 막힌 데를 풀어 줄지 보고 있는 것들입니다.

Bedrock AgentCore

에이전트를 클라우드에서 돌리기

지금 막힌 것

지금 탐지기가 제 노트북에 묶여 있어 팀원이 같은 환경을 맞춰야 돌아갑니다.

Bedrock의 Claude 모델

2단을 다른 회사 모델로 다시 측정

지금 막힌 것

지금은 Amazon Nova 한 묶음만 봤습니다. 사용 목적을 먼저 내야 열립니다.

Amazon CloudWatch

호출을 전부 기록

지금 막힌 것

사다리 수치를 나중에 다시 세려면 어떤 호출이 언제 있었는지 남아야 합니다.

Amazon S3

변조본과 정답지를 한곳에

지금 막힌 것

지금은 각자 노트북과 드라이브에 흩어져 있어 누가 어느 판을 봤는지 맞추기 어렵습니다.

Bedrock Knowledge Bases

논문 전체를 색인해 두고 묻기

지금 막힌 것

근거 확인이 준 글 안에서만 도는 한계를 넘을 수 있을지 보려고 합니다.

고르는 기준은 하나입니다. 지금 걸려 있는 것을 푸는가.

참고: 결함 유형별 판정

AWS 기본 탐지기(Guardrails 근거 확인)를 결함 유형마다 걸어 본 결과입니다.

D1 숫자 불일치 본문과 표의 값이 다름	못 씀	문장은 그대로 두고 숫자만 바꿔 40건. 점수가 0.98에서 0.65로 내려가지만 20건 중 6건만 걸림
D2 없는 인용 가리킨 문헌이나 패널이 없음	쓸 수 있음	실제 문헌과 지어낸 문헌 45건. 실제 0.99, 지어낸 것 0.07로 45건 모두 맞게 갈림
D3 근거보다 센 결론 근거는 그대로 두고 결론만 뒤집음	못 씀	심은 문장 24건이 모두 0점인데 논문의 참인 문장도 0.08이라 구별이 안 됨
D4 결과 지위 오표기 나중에 뺀 것을 처음부터인 것처럼	안 재 봄	따로 설계해 돌린 적이 없음. 못 쓴다는 뜻이 아님

범용 탐지기가 보는 것은 있나 없나 하나입니다. 그래서 D2에만 맞습니다.